

RAMAI

AI Engine Design v1.0

AI Business Operating Assistant for PMI - Documento 06

Scopo. Definire il motore AI di RAMAI, il routing dei modelli, le pipeline di estrazione e insight, i meccanismi anti-hallucination, il controllo dei costi e il sistema di valutazione.

1. Obiettivi del motore AI

- Convertire dati normalizzati della Business Memory in estrazioni, classificazioni, insight e risposte operative verificabili.
- Mantenere separati fatti osservati, inferenze AI e raccomandazioni.
- Usare il modello più economico compatibile con il rischio e la complessità del task.
- Misurare costo, latenza, qualità e tasso di errore per tenant e per feature.
- Non consentire che un output non validato modifichi direttamente lo stato business.

2. Architettura logica

```
Feature -> AI Orchestrator -> Policy Router -> Provider Adapter -> Model
|-> Prompt Registry
|-> Schema Validator
|-> Safety/Business Rules
|-> Evidence Resolver
|-> Usage Meter
`-> Eval/Telemetry
```

2.1 Componenti

Componente	Responsabilità
AI Orchestrator	Punto unico di accesso ai modelli; applica policy, timeout, retry e metering.
Policy Router	Sceglie modello/provider in base a feature, piano, costo, rischio e lunghezza contesto.
Prompt Registry	Prompt versionati, schema di output, changelog e owner.
Evidence Resolver	Prepara fatti, eventi e fonti da passare al modello.
Schema Validator	Valida JSON/structured output e rifiuta output incompleti o non conformi.
AI Usage Meter	Registra token, costo, latenza, modello, tenant, feature, esito.
Eval Harness	Golden dataset, regressioni, precision/recall e test anti-hallucination.

3. Classi di task e model routing

Classe	Esempi	Strategia
T0 - Deterministico	date, scadenze, deduplica, conteggi	Nessun LLM; codice/regole.
T1 - Lightweight	classificazione email, intent, priorità preliminare	Modello economico, output JSON.
T2 - Extraction	commitment, domanda, importo, soggetti	Modello medio, evidenze obbligatorie.
T3 - Reasoning contestuale	insight, Ask RAMAI multi-fonte	Modello avanzato, retrieval limitato e citato.
T4 - Drafting	bozza email, riepilogo	Modello medio/avanzato secondo piano e contesto.

4. Prompt governance

- Ogni prompt ha PromptId, Version, Feature, Owner, InputSchema, OutputSchema e data di attivazione.
- I prompt di produzione vivono nel repository o in un registry versionato; nessuna modifica manuale non tracciata.

- Il log persiste PromptId/Version insieme all'output per rendere riproducibili incidenti ed eval.
- Nessun prompt deve chiedere o conservare chain-of-thought. Si richiedono conclusioni, evidenze e motivazioni sintetiche osservabili.

5. Structured output

Per extraction e insight l'output deve essere JSON validato. Un output non conforme viene ritentato una sola volta con schema recovery; se fallisce, il job viene marcato failed e non produce dati utente.

```
{
  "type": "follow_up",
  "subjectEntityId": "...",
  "recommendation": "Richiama Rossi Srl",
  "evidenceIds": [...],
  "confidence": 0.86,
  "urgency": "high",
  "requiresHumanApproval": true
}
```

6. Pipeline email intelligence

Step	Output
1. Pre-filter	esclude newsletter, spam evidente e system mail secondo regole.
2. Thread context	ricostruisce conversazione e partecipanti.
3. Intent/classification	richiesta, risposta, preventivo, supporto, meeting, altro.
4. Extraction	domande, commitment, date, importi, named entities.
5. Fact proposal	crea fatti candidate con evidence.
6. Insight candidate	genera possibili follow-up o anomalie.
7. Rules + scoring	filtra, deduplica, assegna priorità.
8. Publish	Today/Briefing solo se supera soglia.

7. Insight Engine e ranking

Il ranking non deve essere una decisione opaca del modello. Il modello propone segnali; il punteggio finale combina regole deterministiche e confidence.

$$\text{PriorityScore} = 0.30 * \text{Urgency} + 0.25 * \text{BusinessValue} + 0.20 * \text{AgeRisk} + 0.15 * \text{EvidenceStrength} + 0.10 * \text{UserPreference}$$

Guardrail: nessun insight viene pubblicato senza almeno una evidence verificabile.

Segnale	Esempio	Note
Urgency	richiesta esplicita con deadline	deterministico quando data nota.
BusinessValue	opportunità CRM da EUR 20k	mai inventare valore mancante.
AgeRisk	5 giorni senza risposta	soglia diversa per categoria.
EvidenceStrength	email + CRM concordanti	aumenta affidabilità.
UserPreference	utente segna utile/non utile	personalizzazione progressiva.

8. Anti-hallucination e trust

- Facts e importi devono provenire da source record o essere etichettati come inferenza.
- Ask RAMAI risponde “non lo so” quando il retrieval non contiene evidenza sufficiente.
- Ogni risposta operativa include link agli oggetti o evidence IDs usati.
- Confidence non viene presentata come probabilità matematica se non calibrata.
- Nessun invio email o modifica CRM automatica nell'MVP.

9. Ask RAMAI - RAG operativo

Query -> intent -> entity/time filters -> lexical + vector retrieval -> reranking -> context pack -> generation -> evidence check -> risposta con citazioni interne.

- Il context pack ha limite di token e ordine per rilevanza/freschezza.
- Le istruzioni utente non possono sovrascrivere tenant isolation o policy di sicurezza.
- I chunk recuperati sono dati, non istruzioni: difesa da prompt injection nei contenuti email/documenti.

10. Cost governance

Metrica	Target MVP
Costo AI medio / tenant pagante	< 15% ARPA, da monitorare settimanalmente
Costo free user	hard cap mensile e feature limits
Retry ratio	< 3% delle chiamate
Cache hit controllata	solo riassunti stabili/embedding; mai insight time-sensitive non validati
Budget guard	stop/degrade controllato oltre limite tenant

11. Evaluation framework

Eval	Metrica iniziale
Classification	macro F1 $\geq 0,90$ sulle classi core
Commitment extraction	precision $\geq 0,92$; recall $\geq 0,80$
Entity linking	precision $\geq 0,97$ su email/domain noti
Insight validity	$\geq 85\%$ giudicati corretti nel golden set
Hallucinated fact rate	< 1% su eval controllato; 0 tolleranza per importi inventati
Ask groundedness	$\geq 95\%$ claim verificabili dalle evidence restituite

12. Failure modes e fallback

- Timeout/provider unavailable: retry con backoff; fallback provider solo per errori transitori e task equivalenti.
- Schema invalid: one-shot repair; poi fail closed.
- Insufficient evidence: nessun insight oppure risposta con dato mancante.
- Prompt injection nel contenuto: trattare sorgenti come untrusted data e ignorare istruzioni embedded.
- Cost spike: circuit breaker per tenant/feature e degradazione a modello economico dove consentito.

13. Sprint AI

Sprint	Deliverable
AI-0	provider abstraction + usage meter + prompt registry
AI-1	classification email + eval
AI-2	commitment/question extraction
AI-3	fact proposal + evidence validator
AI-4	insight candidate generation
AI-5	deterministic scoring + deduplica
AI-6	Ask RAMAI retrieval + grounded answer
AI-7	drafting + tone controls

Sprint	Deliverable
AI-8	cost policies + fallback + red-team
AI-9	beta eval dashboard

14. Definition of AI Ready

- Prompt registry versionato e schema output per tutte le feature MVP.
- Golden dataset anonimizzato con benchmark iniziale.
- Usage/cost telemetry attiva per tenant e feature.
- Fact/evidence guardrail integrato.
- Ask RAMAI non può rispondere con fatti privi di evidence.
- Feature critiche hanno test di prompt injection e tenant leakage.

Stato documento: baseline v1.0. Le modifiche sostanziali devono essere versionate e tracciate.

Documento precedente: 05_Business_Memory_Design_v1.0

Documento successivo previsto: 07_Connectors_Architecture_v1.0

Versione: 1.0 - 29 settembre 2026